持续学习如何服务于鲁棒图像隐藏

ContinualSteg · 阶段汇报 / 导师讨论 · 2026.11.10

研究问题：新退化依次出现时，如何兼顾新任务恢复、旧任务保留与载密图像质量？

已完成 五阶段训练与跨阶段评估；旧任务性能基本保持。

当前瓶颈 无攻击恢复质量仍有限；裁剪后的恢复明显下降。

讨论重点 厘清低遗忘来源，确定可验证的机制与实验主线。

当前定位：自建隐藏 / 恢复 CNN 的持续学习原型；尚非原始 HiNet / UDH 的完整整合。

依据：已上传训练 CSV、服务器运行截图及当前仓库代码（f60e05e）。

持续学习体现为：顺序任务 + 旧路径冻结

任务变化来自退化类型；当前实验在编码端、恢复端均使用已知任务编号 t。



clean → 像素量化 → Gaussian → resize → crop

训练阶段	共享骨干	旧任务路径	当前任务路径
初始 clean	训练	—	训练
后续新任务	冻结	冻结	训练

每任务保留独立 Adapter；以参数隔离保留旧能力，参数与存储开销随任务数增加。

代码： continual_steg/models.py · train.py；思路借鉴 RwF 的路径隔离与 AIM 的轻量适配。

最终恢复质量：裁剪是当前最明显的瓶颈

DIV2K： 训练 800 / 验证 100 张； 128×128； 50 轮 / 任务（运行记录），共五阶段。

任务	载密 PSNR ↑	载密 SSIM ↑	恢复 PSNR ↑	恢复 SSIM ↑	载密 APD ↓
clean	23.77	0.743	20.35	0.570	11.45
像素量化 *	22.78	0.670	19.66	0.525	12.67
Gaussian	23.13	0.689	19.80	0.526	12.22
resize	23.24	0.701	20.11	0.552	12.17
crop	**22.61**	**0.701**	**14.90**	**0.232**	**13.59**
任务宏平均	**23.11**	**0.701**	**18.97**	**0.481**	**12.42**

clean 恢复 20.35 dB / 0.570； crop 恢复降至 14.90 dB / 0.232 。

当前 PSNR 按 batch 汇总；五任务均值为宏平均。尚无原始 HiNet / UDH 同协议对照。

来源： metrics [2].csv， stage=4； PSNR： dB， APD： 0–255； *jpeg 为像素量化，非真实 JPEG 。

旧任务几乎不下降，但低遗忘的来源需要辨清

恢复 PSNR 矩阵（dB）：每完成一个新阶段，重新评估所有已学任务。

完成阶段	clean	量化	Gaussian	resize	crop
0 clean	20.35	—	—	—	—
1 像素量化	20.35	19.66	—	—	—
2 Gaussian	20.35	19.66	19.81	—	—
3 resize	20.35	19.66	19.82	20.11	—
4 crop	**20.35**	**19.66**	**19.80**	**20.11**	**14.90**

观察到的遗忘

clean / 量化 / resize 接近 0 dB

Gaussian：约 0.015 dB

crop：暂不可评价

低遗忘与冻结旧路径一致，不能单独归因于 Replay / Distillation 。

来源： metrics [2].csv ； Gaussian 存在随机噪声评估波动；最后任务没有后续遗忘观测。

短消融暴露出：蒸馏尚未形成有效约束

短试验： 5 轮 / 任务 × 20 训练 batch ；仅 5 个验证 batch 。用于排错，不作正式效果比较。

短试验组别	各任务最终恢复 PSNR 区间
full / no_distill / adapter_only	均约 11.74–11.81 dB
sequential_finetune	约 14.29–15.61 dB

蒸馏路径：旧样本 → 已冻结的旧任务路径 → 输出匹配损失

当前任务的可训练参数未参与这条路径，蒸馏损失对它们没有梯度。

no_distill 也没有旧样本监督损失，不能作为“仅 Replay” 的有效消融。

骨干只学 5 轮便冻结也限制了后续恢复。应先修正实验定义，再安排长时间训练。

数值区间来自用户终端截图（非完整消融 CSV ）；机制结论来自 train.py / models.py 静态核对。

形成论文结论前，需收紧三个实验边界

这些是影响实验解释的具体问题；本次汇报不把待修复能力写成已验证成果。

检查项	当前实现	下一步
Prompt 作用	向量 p 与投影 W 同时零初始化 p 、 W 的梯度为 0 ， bias 可更新	检查梯度与参数变化 再修正初始化
真实退化	jpeg 是像素量化 crop 是固定中心裁剪再放大	加入真实 JPEG 与多强度退化 固定同图、同攻击做对照
指标可比性	按 batch 平均指标 Gaussian 每次采样不同噪声	统一逐图统计与评估随机性 完整验证集 + 多随机种子

PSNR / SSIM 衡量失真与恢复；抗隐写检测性尚未评估，不能据此宣称隐写安全。

依据： models.py 的 Prompt 初始化； tasks.py 的退化实现； metrics.py 与 train.py 的评估逻辑。

下一步只做能回答问题的最小对照

建议协议（待确认）：固定同一嵌入器，从同一收敛起点持续训练提取器。

实验组	主要回答的问题
共享提取器：直接顺序微调	新任务适应与旧任务遗忘的基线
冻结骨干 + 独立 Adapter	隔离能保留多少能力？存储成本多少？
共享可训练模块 + 监督回放	回放是否确实改善旧任务保留？
上一组 + 冻结教师蒸馏	蒸馏是否带来额外收益？

统一：图像配对、退化强度、训练预算和评估噪声；完整验证集，至少 3 个随机种子。

交付：恢复质量 × 遗忘 × 参数 / 存储开销；同样本六联图，并保留裁剪失败案例。

以下为计划；当前尚无按此修订协议完成的正式多种子结果。

与导师确认的三个取舍

讨论目标：明确任务假设、方法主线和先验证哪一个原始基线。

1 场景：嵌入后退化是否未知?

建议固定嵌入器，持续适应提取器；

已知任务编号的结果作为条件明确的参考。

2 主线：隔离保留，还是共享适应?

建议以有效回放 / 蒸馏约束共享可训练模块为主线；

独立 Adapter 作为低遗忘与存储成本的对照。

3 基线：先 UDH，还是直接上 HiNet？

建议先在原始 UDH 上建立统一实验；

随后单独处理 HiNet 可逆结构的适配。

参考： HiNet (ICCV 2021) 、 UDH (NeurIPS 2020) 、 RwF 、 AIM ；具体链接与证据见备注及同目录说明。